

Evaluation des Architekturvergleichs: MLP, LSTM und Transformer

Diese Evaluation misst die drei final trainierten Agenten des Vergleichslaufs `model_comparison_final_v2` (PPO, 16,6 Mio. Steps je Architektur, fünf vollständige Curriculum-Schleifen je Environment) auf vier Ebenen: Performance, Lernverhalten, Generalisierung und Fehleranalyse. Datengrundlage sind die vollständigen TensorBoard-Events des Trainings, die env-reinen Episodenprotokolle sowie 2.325 kontrollierte Evaluationsepisoden auf 155 im Training nie gesehenen Karten. Alle Erfolgsraten bezeichnen den Anteil der Episoden mit Zielerreichung; Fehlschläge umfassen Tod durch Lava oder Loch sowie Zeitüberschreitung.

1. Lernverlauf

Abbildung 1 zeigt den Reward-Verlauf über das gesamte Training. Die periodische Struktur spiegelt das Loop-Curriculum (Easy - Medium - Hard): Phasenwechsel zu schwereren Karten senken den Reward systematisch, sind also Curriculum-Artefakte und keine Lerneinbrüche. Aussagekräftig ist die Einhüllende: Das LSTM setzt sich ab etwa 4 Mio. Steps dauerhaft ab und beendet das Training bei einem mittleren Episoden-Reward von +25,4; MLP (+15,8) und Transformer (+12,5) folgen mit deutlichem Abstand. Der Transformer zeigt den charakteristisch langsamsten Anlauf (negativer Reward bis ~1,5 Mio. Steps), holt danach aber kontinuierlich auf.




Abbildung 1: Mittlerer Episoden-Reward (EMA-geglättet) über 16,6 Mio. Trainings-Steps. Die Oszillation folgt den Curriculum-Schleifen.




Abbildung 2: Rollierende Erfolgsrate über das Training. Die Spitzen entsprechen Easy-, die Täler Hard-Phasen der Curriculum-Schleife.

Die Konvergenzkennzahl des Evaluationsplans (Steps bis 80 % der finalen Leistung) beträgt 0,29 Mio. (MLP), 0,30 Mio. (LSTM) und 4,21 Mio. Steps (Transformer); unter einem Loop-Curriculum ist sie wegen der phasenabhängigen Erfolgsrate jedoch nur eingeschränkt interpretierbar. Das robustere Konvergenzmaß ist der Block-über-Block-Vergleich identischer Kartenklassen (Abbildung 3): Auf den Hard-Karten steigert sich das LSTM von 39 % (Block 1) auf 72 % (Block 5), mit abnehmenden, aber bis zuletzt positiven Zuwächsen; der MLP erreicht sein Plateau bei 42 % ab Block 4; der Transformer wächst am langsamsten und zeigt in Block 5 erstmals einen leichten Rückgang (31 auf 28 %), zeitgleich mit der auf ~45 % abgesunkenen Lernrate. Die Trainingsstabilität (Standardabweichung des Rewards über die letzten 200.000 Steps) bestätigt die Literaturerwartung rekurrenter Stabilität: LSTM 1,14 gegenüber Transformer 2,21 und MLP 2,28.




Abbildung 3: Erfolgsrate auf Hard-Karten je Curriculum-Block (Blockmittel). Der Wiederholungsblock-Vergleich isoliert den Lernfortschritt auf konstanter Kartenklasse.

2. Finale Performance

Die finale Leistung (letzte Messfenster des Trainings sowie Trainingskarten-Niveau der fünften Schleife) ordnet die Architekturen eindeutig: LSTM 84 % Gesamterfolg, MLP 59 %, Transformer 45 %. Die Effizienz erfolgreicher Episoden unterscheidet sich dabei kaum - 425 bis 440 Schritte bis zum Ziel über alle drei Architekturen. Der gesamte Leistungsunterschied entsteht durch die Scheiterquote, nicht durch die Wegqualität: Wo alle drei ankommen, sind ihre Pfade gleichwertig. Leistungsunterschiede sind daher als Unterschiede in der Zuverlässigkeit der Gefahrenbewältigung

zu interpretieren.

3. Generalisierung (Held-out und Out-of-Distribution)

Abbildung 4 zeigt die Erfolgsraten auf den 155 ungesehenen Karten. Innerhalb der Trainingsverteilung (Easy/Medium/Hard) reproduzieren sich Rangfolge und Absolutniveau des Trainings nahezu exakt: LSTM 90/88/70 %, MLP 64/62/36 %, Transformer 57/56/30 %. Die Generalisierungslücke (Abbildung 5) liegt zwischen -8 und +6 Prozentpunkten und damit für alle Architekturen in der besten Bewertungskategorie des Evaluationsplans ('sehr gut', < 10); negative Werte - Held-out besser als Training - erklären sich durch die finalen Gewichte der Evaluation gegenüber Blockmitteln des Trainings. Overfitting auf die Trainingskarten ist damit ausgeschlossen; die egozentrische Sensorik ohne globale Karteninformation hat wie beabsichtigt übertragbare Navigationskompetenz erzwungen.




Abbildung 4: Erfolgsraten auf ungesehenen Karten (je 250 Episoden, Giant: 25). Paarweise faire Spawn-/Zielpositionen über die Architekturen.




Abbildung 5: Generalisierungslücke (Trainingskarten minus Held-out) in Prozentpunkten. Alle Werte liegen deutlich unter der 10-Punkte-Schwelle des Evaluationsplans.

Der Out-of-Distribution-Test verschärft die Bedingungen: Die fünf Giant-Karten überschreiten die Trainingsverteilung in Größe (40-50 x 48-60 gegenüber maximal 37 x 45 Zellen), Verzweigungstiefe und Gefahrendichte. Hier trennen sich die Architekturen drastisch: Das LSTM löst 48 % der Episoden und erreicht auf jeder der fünf Karten mindestens einen Erfolg; MLP (16 %) und Transformer (8 %) brechen ein. Das Verhältnis LSTM zu MLP wächst von Faktor 1,4-1,9 innerhalb der Verteilung auf Faktor 3 außerhalb, gegenüber dem Transformer auf Faktor 6. Der Mehrwert temporalen Gedächtnisses skaliert somit nicht nur mit der Aufgabenschwierigkeit, sondern verstärkt sich unter

Verteilungsverschiebung - für reale Einsatzszenarien, die praktisch immer teilweise außerhalb der Trainingsverteilung liegen, der entscheidende Befund.

4. Fehleranalyse

Abbildung 6 zeigt die Fehlschlagsverteilung auf den Hard-Karten am Trainingsende. Timeouts spielen bei allen Architekturen eine marginale Rolle (2-8 %): Kein Agent scheitert an Orientierungslosigkeit, gescheitert wird aktiv an der Gefahrenpräzision. Die Profile sind diagnostisch: Das LSTM weist die niedrigsten Gefahren-Todesraten auf (24 % Lava, 20 % Loch); beim Transformer dominiert der Lava-Tod (40 %) - das zeitkritische Sprungmanöver, ein mehrstufiger Bewegungsablauf aus Anlauf, Absprungzeitpunkt und Flugphase, bleibt seine zentrale ungelöste Teilfähigkeit. Dass gerade die rekurrente Architektur dieses Manöver am zuverlässigsten beherrscht, stützt die Interpretation, dass ein expliziter innerer Zustand ('befinde mich im Sprung') mehrstufige Motorik erleichtert, die eine reaktive Policy aus dem Einzelframe rekonstruieren muss.




Abbildung 6: Fehlschlagsursachen auf Hard-Karten (Training, fünfte Schleife) in Prozent der Episoden.

5. Qualitative Beobachtungen

Die im Evaluationsplan erwarteten Verhaltensprofile bestätigen sich teilweise: Der MLP agiert erkennbar reaktiv und überlebt lange, ohne anzukommen (längste mittlere Episodendauer bei niedrigerer Erfolgsrate); das LSTM navigiert zielstrebig mit kurzen Episoden - schneller Erfolg oder schnelles Scheitern; der Transformer zeigt die erwartete anfängliche Instabilität und die niedrigste finale Entropie (0,91 gegenüber 1,57/1,79), also die deterministischste Policy mit der geringsten Explorationsreserve. Nicht bestätigt hat sich die erwartete Generalisierungsüberlegenheit der Attention-Architektur: Das kurze Kontextfenster (16 Entscheidungen) bot gegenüber dem rekurrenten Zustand keinen messbaren Vorteil, bei zugleich höherem Integrations- und Tuningaufwand.

6. Limitationen der Evaluation

(1) Ein Trainingslauf je Architektur (Seed 42) statt der geplanten drei; Punktwerte ohne Konfidenzintervalle über Runs. Als interne Replikation dienen die Konsistenz über fünf Curriculum-Schleifen, drei Kartenklassen und den unabhängigen Held-out-Test mit paarweiser Seed-Kontrolle. (2) Das Best-vs.-Best-Design konfundiert Architektur- und Hyperparameter-Effekte. (3) Die Hindernisüberwindungsrate ist indirekt belegt (Erfolge auf Lava-Pflicht-Karten), da der direkte Zähler konstruktionsbedingt wirkungslos war. (4) Fünf Giant-Karten sind ein Härte-test, keine

breite OOD-Stichprobe. (5) Der Trainingsabbruch bei 16,6 von 30 Mio. Steps (Kriterium: gleiche Curriculum-Exposition) ließ die Lernraten bei ~45 % des Startwerts stehen; insbesondere der Transformer war auf Hard-Karten nicht sicher auskonvergiert.

7. Zusammenfassung

Die Evaluation beantwortet die Forschungsfragen konsistent über alle vier Messebenen: Temporales Gedächtnis liefert einen erheblichen, mit der Aufgabenschwierigkeit wachsenden und unter Verteilungsverschiebung dominanten Mehrwert (F1); das rekurrente LSTM übertrifft die nachgerüstete Transformer-Policy in jeder Disziplin bei zugleich höherer Trainingsstabilität (F2); und die gemessenen Fähigkeiten generalisieren ohne messbare Lücke auf ungesehene Karten (F3). Die Gesamttrangfolge LSTM vor MLP vor Transformer ist über Training, Held-out und Out-of-Distribution stabil und in der Scheiterquote, nicht der Wegqualität begründet.