

Generalisierungstest: Ergebnisbericht (Forschungsfrage F3)

Evaluation der drei final trainierten Modelle (model_comparison_final_v2, Checkpoint 16,6 Mio. Steps) auf 155 im Training nie gesehenen Karten. Durchgefuehrt am 11.07.2026, 17:10-19:10 Uhr; 2.325 Bewertungsepisoden, vollstaendig protokolliert in results/generalization/generalization_results_run1.csv.

1. Testaufbau und Methodik

Getestet wurde in einer dedizierten Evaluationsszene mit drei parallelen Arealen - je eines pro Architektur mit genau einem Agenten -, abgeleitet aus der Trainingsszene und damit mit exakt identischer Sensorik (31 Vektor-Observations inklusive Zielrichtungsvektor plus Ray-Sensorik). Der Kartensatz umfasst 50 Easy-, 50 Medium- und 50 Hard-Karten aus demselben prozeduralen Generator wie das Training, jedoch mit disjunktem Seed-Bereich (In-Distribution-Held-out), sowie 5 Giant-Karten einer eigens definierten Schwierigkeitsstufe jenseits der Trainingsverteilung (40-50 x 48-60 Zellen gegenueber maximal 37 x 45 im Training, mehr Korridore, tiefere Verzweigungen, hoehere Gefahrendichte). Jede Karte wurde fuenfmal gespielt; pro Episode erhielten alle drei Areale denselben Zufalls-Seed, sodass Spawn- und Zielposition ueber die Architekturen identisch ausgewuerfelt wurden - der Vergleich ist paarweise fair. Ein Zeitlimit je Kartenkategorie (45/75/110/180 simulierte Sekunden) begrenzte jede Episode; Tod oder Timeout zaehlt als Fehlschlag.

Die Inferenz lief nicht ueber die Unity-interne ONNX-Runtime, sondern ueber den Python-Trainer im Inference-Modus (mlagents --inference --resume): Die Agenten wurden von exakt den Policy-Implementierungen gesteuert, mit denen sie trainiert wurden. Ausschlaggebend war ein Kompatibilitaetsbefund: Der Transformer-Graph des torch-2.3-Exports ist mit der im Projekt eingesetzten Barracuda-Runtime nicht lauffaehig (nicht unterstuetzter If-Operator, inkompatible Attention-Reshapes) - dieselbe Problemklasse, die in Milestone 7 die Export-Iterationen erzwang. Der Python-Inferenz-Weg umgeht jede Konvertierung und eliminiert damit zugleich Fidelitaetsfragen zwischen Trainings- und Evaluationsverhalten.

2. Ergebnisse

Erfolgsraten (Anteil Episoden mit Zielerreichung) je Kartenkategorie, 250 Episoden je Architektur und Kategorie (Giant: 25):

Kategorie	LSTM	MLP	Transformer
Easy (50)	90,4 %	64,0 %	57,2 %
Medium (50)	88,4 %	61,6 %	56,0 %
Hard (50)	69,6 %	36,4 %	29,6 %
Giant (5,00D)	48,0 %	16,0 %	8,0 %

Kartenabdeckung (mindestens ein Erfolg in fuenf Versuchen / fehlerfrei 5 von 5):

Kategorie	LSTM	MLP	Transformer
Easy	50/50 (34x5/5)	44/50 (13x5/5)	44/50 (13x5/5)
Medium	50/50 (32x5/5)	45/50 (12x5/5)	44/50 (9x5/5)
Hard	48/50 (14x5/5)	38/50 (1x5/5)	37/50 (0x5/5)
Giant	5/5 (0x5/5)	2/5 (0x5/5)	1/5 (0x5/5)

Die mittlere Dauer erfolgreicher Episoden liegt fuer alle drei Architekturen nahezu gleichauf (Easy ~5 s, Medium ~7,5 s, Hard 13-16 s, Giant 14-16 s simulierte Zeit): Wo die Agenten ankommen, sind ihre Wege gleichwertig - der gesamte Leistungsunterschied entsteht durch die Scheiterquote. Dieser Befund reproduziert das Trainingsergebnis und stuetzt die Interpretation, dass die Architekturen sich in der Zuverlaessigkeit der Gefahrenbewaeltigung unterscheiden, nicht in der Pfadqualitaet.

3. Befund 1: Keine Generalisierungsluecke innerhalb der Trainingsverteilung

Der Vergleich mit den finalen Trainingswerten (Blockmittel der fuenften Curriculum-Schleife) zeigt fuer alle drei Architekturen eine Generalisierungsluecke von praktisch null: Easy 90,4 gegenueber 83-85 Prozent im Training, Medium 88,4 gegenueber ~83, Hard 69,6 gegenueber 72 Prozent (LSTM; MLP und Transformer analog mit Abweichungen von -6 bis +12 Punkten ohne systematische Richtung). Dass Held-out-Werte teils ueber den Trainingswerten liegen, erklart sich methodisch: Die Evaluation nutzt die finalen Gewichte, waehrend Blockmittel auch schwachere fruehe Episoden des jeweiligen Blocks enthalten. Der Overfitting-Index (Differenz Training minus Held-out) liegt damit bei etwa null - die Agenten haben ihre Erfolgsraten nicht durch Kartengedaechtnis erzielt, sondern durch uebertragbare Navigationsfaehigkeiten. Das bestaetigt die zentrale Designentscheidung der Umgebung: Eine rein egozentrische, lokale Sensorik ohne globale Karteninformation macht Auswendiglernen strukturell unmoeglich, und zufaellige Spawn-/Zielpositionen verwandeln bereits das Training in eine implizite Generalisierungsuebung.

4. Befund 2: Out-of-Distribution trennt die Architekturen dramatisch

Auf den fuenf Giant-Karten - groesser und strukturell komplexer als alles im Training Gesehene - loest das LSTM noch knapp die Haelfte aller Episoden (48 Prozent) und erreicht auf jeder der fuenf Karten mindestens einen Erfolg. MLP (16 Prozent, zwei von fuenf Karten) und Transformer (8 Prozent, eine Karte) brechen dagegen ein. Bemerkenswert ist das Verhaeltnis: Innerhalb der Verteilung trennt das LSTM vom MLP der Faktor 1,4 bis 1,9 - ausserhalb waechst er auf 3, beim Transformer auf 6. Der Vorteil temporalen Gedaechtnisses skaliert also nicht nur mit der Schwierigkeit, sondern verstaerkt sich jenseits der Trainingsverteilung: Auf ueberlangen Wegen mit vielen Verzweigungen degradiert die rekurrente Policy graeziler als die reaktive Baseline und die Attention-Variante. Fuer die praktische Uebertragbarkeit (Kapitel 9 der Arbeit) ist das der relevanteste Einzelbefund: Reale Einsatzumgebungen liegen praktisch immer teilweise ausserhalb der Trainingsverteilung.

5. Einordnung fuer F1 und F2

Der Generalisierungstest bestaetigt die Trainingsbefunde unter verschaeften Bedingungen und vervollstaendigt damit die Beantwortung aller drei Forschungsfragen. F1 (Mehrwert temporalen Gedaechtnisses): auf ungesesehenen Karten +26 bis +33 Prozentpunkte gegenueber der Baseline, auf OOD-Karten Faktor 3. F2 (LSTM vs. Transformer): Das LSTM dominiert in jeder Kategorie; der Transformer liegt auf ungesesehenen Karten sogar knapp hinter der gedaechtnislosen Baseline - sein im Training beobachteter Rueckstand (Lava-Praezision) uebertraegt sich unveraendert. F3 (Generalisierung): keine messbare Luecke in-distribution, klar abgestufte, architekturabhaengige Degradation out-of-distribution.

6. Limitationen

(1) Fuenf Giant-Karten sind ein Haertetest, keine statistisch breite OOD-Stichprobe; die Groessenordnungen (48 vs. 16 vs. 8 Prozent bei je 25 Episoden) sind aussagekraeftig, die Nachkommastellen nicht. (2) Die Zeitlimits je Kategorie setzen die Erfolgsmassstaebe; laengere Budgets wuerden alle Absolutwerte heben (die Giant-Grenze von 180 simulierten Sekunden ist bewusst grosszuegig gewaehlt, ca. das Sechsfache der mittleren Erfolgszeit). (3) Ein Evaluationslauf pro Modell; die paarweise Seed-Kontrolle eliminiert jedoch die wichtigste Varianzquelle (Spawn-/Ziel-Wuerfe) zwischen den Architekturen. (4) Die Python-Inferenz entspricht exakt dem Trainingsverhalten; fuer einen Unity-nativen Einsatz des Transformers bleibt die Barracuda-Inkompatibilitaet des Exports als offener technischer Punkt bestehen (Loesungspfade: Sentic-Migration oder die Milestone-7-Export-Pipeline).

7. Fazit

Der Test liefert das methodisch wichtigste Resultat der Arbeit: Die im Training gemessenen Leistungsunterschiede sind echte, uebertragbare Faehigkeitsunterschiede - nicht Artefakte der Trainingskarten. Die Rangfolge LSTM vor MLP vor Transformer ist auf ungesehenem Terrain stabil, die Absolutwerte bleiben erhalten, und unter Verteilungsverschiebung waechst der Abstand des rekurrenten Gedaechnisses auf das Drei- bis Sechsfache. Zusammen mit den Trainingsbefunden ergibt sich ein konsistentes Gesamtbild: Temporales Gedaechnis ist fuer zuverlaessige Navigation in teilbeobachtbaren, gefahrenbehafteten Umgebungen nicht optional, sondern der entscheidende Architekturfaktor - und seine Bedeutung waechst genau dort, wo es praktisch darauf ankommt: jenseits der bekannten Verteilung.