

Generalisierungstest final_v3 (Finn, 30 M Steps) — Ergebnisbericht

Evaluation der final trainierten 30-Mio.-Steps-Modelle des Vergleichslaufs model_comparison_final_v3 (Training abgeschlossen 2026-07-11 auf GPU-Hardware) auf denselben 155 im Training nie gesehenen Karten wie der final_v2-Test. Durchgeführt 2026-07-12; 2.325 Bewertungsepisoden. Datenquelle: results/generalization/generalization_results_finn_v3.csv.

1. Aufbau (identisch zu final_v2)

Testszene, Kartensatz (50 Easy / 50 Medium / 50 Hard / 5 Giant, disjunkte Held-out-Seeds), fünf Episoden je Karte mit paarweise identischen Spawn-/Zielpositionen über die Architekturen sowie die Python-Inferenz-Betriebsart sind mit dem final_v2-Test deckungsgleich — der einzige Unterschied sind die geladenen Gewichte (Finns 30-M-Checkpoints statt unserer 16,6-M-Modelle). Technische Besonderheit: Finns Checkpoints wurden auf GPU gespeichert und mussten für die CPU-Maschine per map_location='cpu' konvertiert werden (verlustfrei); danach luden alle drei Modelle sauber (Resume ab Step 30.000.089 / 30.003.930 / 30.006.822).

2. Ergebnisse




Abbildung 1: Erfolgsraten der final_v3-Modelle auf den 155 ungesehenen Karten (je 250 Episoden, Giant 25).

Kategorie	LSTM	MLP	Transformer
Easy (50)	8,0	78,4	84,4
Medium (50)	4,0	83,6	79,6
Hard (50)	0,8	63,6	56,4
Giant (5)	0,0	40,0	52,0

Rangfolge final_v3: MLP und Transformer liegen dicht beieinander und dominieren (Transformer auf Easy und Giant knapp vorn, MLP auf Medium und Hard); das LSTM fällt in allen Kategorien auf 0–8 % ab. Karten-Abdeckung: MLP und Transformer erreichen auf 43–49 von 50 Karten je Kategorie mindestens einen Erfolg (und lösen 11–34 Karten fehlerfrei 5-von-5); das LSTM erreicht überhaupt nur auf 15 Easy-, 9 Medium-, 2 Hard- und 0 Giant-Karten je einen Treffer und keine einzige Karte fehlerfrei.

3. Der LSTM-Kollaps — Ursachenabgrenzung

Der Einbruch des final_v3-LSTM auf 0–8 % ist das auffälligste Einzelresultat. Zwei Kontrollen grenzen

die Ursache ein. Erstens die Testharness: Exakt dieselbe Szene, dieselben Held-out-Karten und derselbe Python-Inferenz-Pfad lieferten für das final_v2-LSTM 90,4 % auf Easy — ein Harness- oder Infrastrukturfehler scheidet damit aus, die Ursache liegt eindeutig in den Modellgewichten. Zweitens die Trainings-Held-out-Lücke: Der final_v3-LSTM erreichte im Training zuletzt eine Rolling-Erfolgsrate von ~57,5 %, generalisiert aber nur mit 4–8 % — eine Lücke von rund 50 Punkten, während MLP und Transformer nur kleine Lücken zeigen. Dieses Profil ist charakteristisch für eine späte Instabilität oder Überanpassung der rekurrenten Policy: Bereits im Training lag die Rolling-Rate des LSTM am Laufende unter seinem besten je erreichten Niveau (74,3 %), es hatte also schon vor Trainingsende wieder an Leistung verloren. Die genaue Ursache (rekurrente Zustandsdegeneration, Overfitting auf Trainingslayouts, oder ein spezifischer Effekt der 30-M-Loop-Curriculum-Dynamik) ist ohne die Roh-Trainingsdaten des v3-Laufs nicht abschließend bestimmbar.

4. Fazit

Der final_v3-Test zeigt eine gegenüber final_v2 vollständig umgekehrte Rangfolge: Statt LSTM > MLP > Transformer nun MLP $\approx$ Transformer > LSTM. MLP und Transformer generalisieren mit Finns 30-M-Modellen deutlich besser als unsere 16,6-M-Modelle (z. B. Hard: MLP 63,6 % statt 36,4 %, Transformer 56,4 % statt 29,6 %), und der Transformer gewinnt sogar den Out-of-Distribution-Härtetest (Giant 52 %). Das LSTM dagegen ist in final_v3 auf ungesesehenen Karten praktisch funktionslos. Die Gegenüberstellung beider Läufe (separater Vergleichsbericht) macht daraus den zentralen methodischen Befund: Die Architektur-Rangfolge ist über zwei Läufe hinweg nicht stabil.