

Trainingsabschlussbericht: model_comparison_final_v2

Direkter Architekturvergleich MLP / LSTM / Transformer unter identischen Umgebungsbedingungen. Lauf vom 09.07.2026, 14:41 Uhr bis 11.07.2026, 16:57 Uhr (rund 50 Stunden). Endpunkt: definiertes Abbruchkriterium 'fünf vollständige Curriculum-Schleifen je Environment' bei ca. 16,6 Mio. Steps je Architektur. Finale Modelle: die Checkpoint-Exporte -16599xxx.onnx vom 11.07., 16:56 Uhr. Datengrundlage dieses Berichts: TensorBoard-Events, Episoden-Logs der Environments, Curriculum-Protokolle und der Stopp-Wächter-Report.

1. Ausgangslage und Setup

Der Lauf ist die korrigierte Wiederholung des ersten finalen Vergleichs (model_comparison_final, 09.07., bei 4 Mio. Steps beendet). Dessen zentraler Befund: MLP und LSTM lernten die Aufgabe, der Transformer blieb trotz seiner in Milestone 7 erprobten Konfiguration nahezu erfolglos (~1 % Erfolg auf Hard-Karten) - als Ursache wurde die fehlende Zielrichtungs-Observation identifiziert, für die seine Hyperparameter ursprünglich abgestimmt worden waren. v2 setzte drei Änderungen um: (1) Rückkehr des Zielrichtungsvektors in den für alle drei Architekturen identischen Beobachtungsraum (31 Vektor-Observations plus Ray-Sensorik), (2) ein Loch-Vermeidungs-Penalty als Gegenstück zum Lava-Sprung-Bonus, (3) ein 8-Phasen-Curriculum mit isolierten Gefahren-Lernstufen (TrivialHole, TrivialLava, TrivialHazard), Erfolgsraten-Gates bis Medium und einer Wiederholungsschleife Easy-Medium-Hard. Trainer-Konfigurationen nach dem Prinzip Best vs. Best (konstitutiv verschieden nur memory_type); Durchsatz: drei parallele Environments, time-scale 40, threaded Training, im Mittel ~345.000 Steps pro Stunde.

2. Verlauf und markante Wendungen

Der Start bestätigte die v1-Diagnose in ungewöhnlicher Geschwindigkeit: Das Trivial-Gate fiel nach 521 Episoden mit exakt 40 %, das Korridor-Gate mit 80 % - Werte, für die v1 Stunden gebraucht hatte, erreichte v2 in Minuten. Die Agenten mussten das Ziel nicht mehr suchen, sondern nur noch den Weg dorthin lösen. Die neue Loch-Phase wurde mit 78 % Erfolgsrate bestanden, die isolierte Lava-Phase mit 34 %, und die kombinierte Gefahrenstufe TrivialHazard - der historische Stolperstein, an dem der V14-Transformer in Milestone 7 endgültig gescheitert war - fiel mit 51 %. Nach gut vier Stunden war das Curriculum erstmals vollständig durchlaufen.

Die erste markante Wendung betraf den Transformer: In v1 praktisch chancenlos, löste er in v2 bereits im ersten Hard-Block 16 bis 19 Prozent der schwersten Karten - mit positivem Reward und über die folgenden Blöcke stetig wachsend. Damit war experimentell belegt, dass sein v1-Versagen ein Informations-, kein Architekturproblem war: die wichtigste Einzelerkenntnis des gesamten Vergleichsprojekts. Die zweite Wendung betraf die Rangfolge: Hatte in v1 der MLP die Führung übernommen, dominierte in v2 durchgängig das LSTM - auf jeder Kartenklasse, in jedem Block, mit wachsendem Abstand. Die dritte Wendung war eine widerlegte Prognose: Nach Hard-Block 3 (59 % Blockmittel beim LSTM) deutete der abflachende Zuwachs auf eine Sättigung um 65 Prozent - Block 4 brachte jedoch weitere zehn Punkte und Block 5 schloss bei 72 % Blockmittel; die Wiederholungsschleife trug deutlich länger, als die Blocktrends nahelegten.

Der Lauf blieb technisch makellos: keine einzige ungeplante Unterbrechung über 50 Stunden - die Härtingsmaßnahmen aus v1 (Puffer-Dimensionierung, Curriculum-Persistenz, Episoden-Timeouts)

hatten Bestand. Zwei Befunde aus laufender Beobachtung sind festzuhalten: Erstens erwies sich der Lava-Überquerungs-Bonus (+8) als seit jeher wirkungsloser Code - die Landungserkennung feuert konstruktionsbedingt nie; gelernt wurde der Lava-Sprung nachweislich aus Anflug-Bonus, Distanz-Shaping und Zielprämie. Da alle Architekturen identisch betroffen sind, bleibt die Fairness unberührt; die effektive Belohnungsfunktion weicht aber von der dokumentierten ab. Zweitens drifteten die drei parallelen Environments im Curriculum zeitlich auseinander (jedes zählt Episoden eigenständig), wodurch Block-Zuordnungen über die globale Step-Achse an den Rändern unscharf werden - die env-reinen Episoden-Logs bleiben davon unberührt.

Beendet wurde der Lauf über ein definiertes Endpunkt-Kriterium statt des 30-Mio.-Step-Budgets: Ein Wächterprozess überwachte die Curriculum-Zustände und stoppte das Training, nachdem jedes Environment seinen fünften Hard-Block abgeschlossen hatte (15:08, 16:05 und 16:45 Uhr) und der nächste Checkpoint-Export die finalen Gewichte gesichert hatte (16:56 Uhr). Jedes Environment hat damit exakt dieselbe Curriculum-Exposition erfahren; früher fertige Environments erzeugten einen kleinen, protokollierten Datenüberhang in der sechsten Schleife.

3. Ergebnisse: Lernverlauf über die Curriculum-Schleifen

Erfolgsraten (Anteil Episoden mit Zielerreichung) als Blockmittel je Wiederholungsblock; Zeilen: Architektur, Spalten: Block 1 bis 5. Werte in Prozent, aus TensorBoard-Events segmentiert (Blockgrenzen wegen Environment-Drift auf wenige Punkte genau).

EASY		B1		B2		B3		B4		B5
LSTM		51		72		79		80		83-85
MLP		46		60		60		57		61-63
Transf.		11		42		48		46		47-51
MEDIUM		B1		B2		B3		B4		B5
LSTM		50		62		73		75		~83
MLP		39		46		53		50		~58
Transf.		27		34		40		39		~44
HARD		B1		B2		B3		B4		B5
LSTM		39		52		59		69		72
MLP		26		28		34		42		42
Transf.		19		22		25		31		28

Zum Laufende (letzte Messfenster, Mischung aus Schleifen-Überhang): LSTM 86 % Erfolg bei Reward +25,4; MLP 61 % bei +15,8; Transformer 48 % bei +12,5. Die Fehlermodi blieben über den gesamten Lauf diagnostisch konsistent: Timeouts spielten ab der ersten Schleife praktisch keine Rolle mehr (1-3 %) - gescheitert wurde aktiv, an Lava- und Loch-Präzision. Das LSTM wies durchgängig die niedrigsten Gefahren-Todesraten auf (Hard zuletzt ~24 % Lava, ~20 % Loch), der Transformer die höchste Lava-Quote (37-46 %): Das zeitkritische Sprungmanöver blieb seine zentrale ungelöste Teilfähigkeit. Aufschlussreich zudem: Die Wege erfolgreicher Episoden waren bei allen drei Architekturen nahezu gleich lang (~425-440 Steps bis zum Ziel) - der Leistungsunterschied liegt vollständig in der Scheiterquote, nicht in der Wegeffizienz.

4. Limitationen

(1) Best vs. Best konfundiert Architektur- und Hyperparameter-Effekte; Leistungsunterschiede sind

nicht allein der Netzstruktur zuzuschreiben. (2) Ein Lauf, ein Seed: Ohne Wiederholungsläufe sind die Differenzen nicht inferenzstatistisch abgesichert; die Konsistenz über fünf Wiederholungsblöcke und drei Kartenklassen ist jedoch ein starkes internes Replikationssignal. (3) Der Abbruch bei 16,6 von 30 Mio. Steps ließ die Lernraten bei ~45 % ihres Startwerts stehen - insbesondere Transformer und MLP waren auf Hard noch nicht sicher auskonvergiert (Transformer fiel in Block 5 leicht zurück, was sowohl Rauschen als auch beginnende LR-Limitierung sein kann). (4) Der wirkungslose Überquerungs-Bonus und die Environment-Drift sind als Abweichungen zwischen dokumentiertem und effektivem Experiment auszuweisen. (5) Erfolgsraten hängen an der MaxStep-Vorgabe je Phase; andere Zeitbudgets verschieben die Absolutwerte.

5. Fazit

Der Lauf beantwortet die ersten beiden Forschungsfragen mit ungewöhnlich klaren, über fünf Schleifen stabilen Befunden. Zum Gedächtnis-Mehrwert (F1): Das LSTM übertrifft die gedächtnislose Baseline auf jeder Kartenklasse deutlich - auf den schwersten Karten zuletzt um 30 Prozentpunkte (72 % vs. 42 %) bei zugleich saubererem Fehlerprofil. Der Mehrwert wächst mit der Aufgabenkomplexität: Auf Easy trennen beide ~20 Punkte, auf Hard ~30. Temporales Gedächtnis zahlt sich dort aus, wo mehrdeutige Situationen und mehrstufige Manöver (Lava-Sprung) dominieren. Zum Architekturvergleich (F2): Das LSTM schlägt den Transformer durchgängig und deutlich (Hard: 72 % vs. 28 %). Dabei ist die eigentliche Pointe des Doppellaufs v1/v2, dass diese Aussage erst durch die Beobachtungsraum-Korrektur belastbar wurde: Der v1-Transformer scheiterte an fehlender Zielinformation, nicht an seiner Architektur - in v2 lernte er die komplette Aufgabe inklusive der Gefahren-Stufen, nur langsamer und mit niedrigerem Plateau als das LSTM. Ob dieses Plateau der Attention-Architektur selbst, ihrer konservativen Lernrate oder der Eigenimplementierung der Policy geschuldet ist, kann dieser Lauf konstruktionsbedingt nicht trennen.

Methodisch hat sich das v2-Design bewährt: Die isolierten Gefahren-Lernstufen mit Erfolgs-Gates verhinderten das aus V14 und v1 bekannte Phasen-Aussitzen vollständig - jede Phase wurde über nachgewiesene Kompetenz verlassen. Die Wiederholungsschleife erwies sich als der wirksamste einzelne Mechanismus des Curriculums: Sie verwandelte einmalige Phasendurchläufe in messbare Lernkurven (Block-Matrizen), lieferte den Nachweis rückwirkender Generalisierung (Easy-Leistung stieg durch Hard-Training) und trug das LSTM zwei Blöcke über seine prognostizierte Sättigung hinaus. Der definierte Endpunkt 'gleiche Curriculum-Exposition je Environment' ersetzt das willkürliche Step-Budget durch ein inhaltlich begründetes Kriterium. Offen bleibt die dritte Forschungsfrage: Die hier gemessenen Erfolgsraten entstammen Karten, deren Verteilung - und in 192 Fällen deren exakte Layouts - die Agenten aus dem Training kennen. Der vorbereitete Generalisierungstest (155 ungesehene Karten inklusive fünf übergroßer Out-of-Distribution-Layouts, identische Spawn/Ziel-Würfe je Architektur) prüft als nächster Schritt, ob die Rangfolge und die Absolutwerte auf wirklich neuem Terrain Bestand haben.

6. Artefakte und nächste Schritte

Artefakte: finale Modelle (results/model_comparison_final_v2/<Behavior>/-16599xxx.onnx), vollständige TensorBoard-Events, stündliche Verlaufs-Reports (Analyse/final_v2/), Stopp-Protokoll mit Env-Zeitstempeln (loop5_stop_protokoll.txt). Nächste Schritte: (1) Zuweisung der finalen ONNX-Modelle in die Generalisierungstest-Szene, (2) Durchführung des Tests (2.325

Bewertungsepisoden, Ergebnis-CSV), (3) Gesamtauswertung F1-F3 für Kapitel 8 der Arbeit.