

Vergleich der beiden finalen Läufe: final_v2 vs. final_v3

Gegenüberstellung der zwei unabhängig durchgeführten finalen Vergleichsläufe — final_v2 (auf dem alxbe-Rechner, 16,6 Mio. Steps, Abbruch nach fünf Curriculum-Loops) und final_v3 (auf Finns GPU-Rechner, volle 30 Mio. Steps) — sowohl im Trainingsverlauf als auch im Generalisierungstest auf 155 identischen ungesehenen Karten. Stand: 2026-07-12.

1. Was sich zwischen den Läufen unterscheidet

Die beiden Trainer-Konfigurationen sind bis auf vier Transformer-Hyperparameter identisch: final_v3 verwendet für den Transformer beta 5e-4 (konstant statt 1e-3 linear), eine konstante statt lineare Lernraten-Abklingung und eine Curiosity-Stärke von 0,02 statt 0,05. Die MLP- und LSTM-Konfigurationen sind zwischen v2 und v3 byte-identisch. Weitere Unterschiede liegen außerhalb der YAML: Trainingsbudget (16,6 vs. 30 Mio. Steps), Parallelität (3 vs. 5 Environments), Hardware (CPU-nah vs. GPU) und die mlagents-/Torch-Umgebung des jeweiligen Rechners. Ein wichtiger methodischer Punkt: Beide Läufe nutzen denselben Seed 42, sind also keine kontrollierte Seed-Wiederholung, sondern zwei Läufe unter teils verschiedenen Bedingungen.

2. Unterschied im Training

Der Trainingsverlauf von final_v3 (Abbildung 1, bestes je erreichtes Erfolgsniveau) zeigt eine andere Dynamik als final_v2: Der MLP steigt am schnellsten und höchsten (89 % bei 14 Mio. Steps), der Transformer holt kontinuierlich auf (36 % → 79 %), und das LSTM bleibt zurück (Plateau um 56 %, am Ende 74 %). In final_v2 war es umgekehrt — dort führte das LSTM klar. Am Laufende erreichen in v3 alle drei einen fast identischen momentanen Reward (~16,4), während die besten Erfolgsraten mit 88,6 % (MLP), 79,0 % (Transformer) und 74,3 % (LSTM) auseinanderliegen.




Abbildung 1: Trainingsverlauf final_v3 (Quelle: stündliche Report-Artefakte, da Roh-tfevents nicht versioniert).

3. Unterschied in der Generalisierung

Der direkte Vergleich der Held-out-Erfolgsraten (Abbildungen 2 und 3) offenbart eine vollständige Umkehr der Rangfolge. In final_v2 dominiert das LSTM auf allen Kategorien (Easy 90 %, Hard 70 %, Giant 48 %), MLP und Transformer folgen mit Abstand. In final_v3 kehrt sich das Bild um: MLP und Transformer generalisieren stark (Easy 78–84 %, Hard 56–64 %), das LSTM kollabiert auf 0–8 %.




Abbildung 2: Held-out-Erfolg final_v2 (16,6 M) — LSTM dominiert.




Abbildung 3: Held-out-Erfolg final_v3 (30 M) — MLP und Transformer dominieren, LSTM kollabiert.

Verdichtet man je Architektur über Easy/Medium/Hard (Abbildung 4), ergibt sich die Kernaussage in einem Bild: Das LSTM fällt von 83 % (v2) auf 4 % (v3), während der MLP von 54 % auf 75 % und der Transformer von 48 % auf 73 % steigen. MLP und Transformer profitieren also erheblich vom längeren Training (und der Transformer zusätzlich von seinen angepassten Hyperparametern), während das LSTM den umgekehrten Weg geht.




Abbildung 4: Mittlerer Held-out-Erfolg (Easy/Medium/Hard) je Architektur, v2 gegen v3.

4. Interpretation

Drei Effekte überlagern sich. Erstens das Trainingsbudget: Mit 30 statt 16,6 Mio. Steps haben MLP und Transformer ihre Leistung deutlich gesteigert — auf den schwersten Karten nahezu verdoppelt. Zweitens die Transformer-Hyperparameter: Die konstante, sanftere Exploration (beta $5e-4$, Curiosity 0,02) und die konstante Lernrate haben den Transformer von einem Nachzügler zu einer der beiden besten Architekturen gemacht — bis hin zum Sieg auf den Out-of-Distribution-Giant-Karten. Drittens, und am gewichtigsten, der LSTM-Kollaps: Da die LSTM-Konfiguration zwischen beiden Läufen identisch ist, kann er nicht auf Hyperparameter zurückgehen. Die wahrscheinlichste Erklärung ist eine späte Instabilität der rekurrenten Policy im 30-M-Lauf — im Training lag die Erfolgsrate des LSTM am Ende bereits unter seinem eigenen Bestwert, und die riesige Trainings-Held-out-Lücke (57 % vs. 4–8 %) deutet auf Überanpassung statt übertragbarer Navigation. Eine Harness-Ursache ist ausgeschlossen: Dieselbe Testinfrastruktur bescheinigte dem v2-LSTM 90 %.

5. Konsequenz für die Arbeit

Der wichtigste übergreifende Befund ist kein einzelnes Erfolgsranking, sondern dessen Instabilität: Zwei Läufe derselben drei Architekturen in derselben Umgebung liefern gegensätzliche Rangfolgen. Das ist die stärkste denkbare empirische Begründung für die im Evaluationsplan geforderte Wiederholung über mehrere Seeds — ein einzelner Lauf je Architektur erlaubt keine belastbare Aussage darüber, welche Architektur „besser“ ist. Für die Dokumentation folgt daraus, beide Läufe als das zu behandeln, was sie sind: zwei Stichproben aus einer verrauschten Verteilung, deren Streuung selbst das eigentliche Ergebnis ist. Belastbar über beide Läufe hinweg bleibt allein, dass alle drei Architekturen die Aufgabe grundsätzlich lösen können und dass kein Overfitting auf konkrete Trainingskarten vorliegt, wo die Modelle überhaupt funktionieren (Generalisierungslücke ≈ 0 bei MLP/Transformer in beiden Läufen und beim v2-LSTM).