

Von Milestone 7 bis heute: Chronologie der Architektur-Integration und der finalen Vergleichsläufe

Fortsetzung der Aufbauphase (M1-M6). Quellen: Git-Historie (Branches milestone-7, Messe2, ModelTrainingComparsion), Trainingsartefakte (results/, Analyse/), Trainings- und Analyse-Logs. Stand: 10.07.2026.

Ende April: Start Milestone 7 - die Trainingsumgebung wird erweiterbar

Mit Milestone 7 beginnt die Integration der Gedächtnisarchitekturen. Da ML-Agents keine Transformer-Memory-Policy mitbringt, fällt die Grundsatzentscheidung gegen einen Framework-Fork und für einen venv-Patch: patch_mlagents.py rüstet die Transformer-Policy reproduzierbar in die Python-Umgebung nach (transformer_policy.py, Erweiterungen an settings.py und networks.py), start_training.py wendet den Patch automatisch an. Am 20. April wird der Patch pfad-portabel gemacht, am 23. April werden Seed 42 und phasenspezifische Episodenlängen fixiert - die Experimentierkonstanten der gesamten Folgezeit.

12.-13. Mai: V13 läuft, V14 scheitert lehrreich

Nach einer Serie von Integrations-Iterationen ist der Transformer mit V13 lauffähig (Commit 'Transformer bis V13', 12. Mai); am selben Tag wird die Typst-Dokumentation initialisiert und parallel ein MLP-Referenztraining gestartet. V14 absolviert anschließend als erster Lauf ein vollständiges Curriculum über gut 31 Millionen Steps - und scheitert diagnostizierbar (Commit 'Transformer V14 Versagt', 13. Mai): Der Agent bewältigt insbesondere den Übergang von isolierten zu kombinierten Gefahrenszenarien nicht und entwickelt Curriculum-Pathologien wie das Aussitzen von Phasen über die Episodenschwelle. Die V14-Diagnose wird zur wichtigsten Referenz der folgenden Wochen: Sie motiviert die Nachbereitung 'Vorbereitung V15, viele Änderungen' und später die isolierten Gefahren-Lernstufen des finalen Curriculums.

17.-26. Mai: Iterationsserie V15-V24 und MLP-Langzeitlauf

In dichter Folge werden die Diagnosen abgearbeitet: V15 (Lauf und Nachbereitung, 17. Mai), V16 und V17 (18. Mai), V18 und V19 (19. Mai), V20 und V21 (20. Mai), schließlich der Stand 'bis V24' (26. Mai). Die Iterationen umfassen Hyperparameter-Korrekturen (u. a. Lernrate und Entropie-Koeffizient, die als V6-/V7-Fixes in die spätere Vergleichskonfiguration eingehen), Reward- und Curriculum-Anpassungen sowie die ONNX-Export-Kette für die Unity-Inferenz (Batch-Size-1-Export, LayerNorm-Korrekturen, separates Export-venv). Parallel schließt das MLP-Langzeittraining am 23. Mai mit rund 20,8 Millionen Steps ab und liefert die belastbare Baseline-Referenz. Der LSTM-Strang durchläuft im selben Zeitraum seine Iterationen lstm_v1 bis v7b mit den bleibenden Erkenntnissen zu Normalisierung (normalize: true) und Gedächtnisdimensionierung (sequence_length 16, memory_size 256).

23.-27. Mai: Messe-Demonstrator (Branch Messe2)

Aus dem V24-Stand entsteht binnen weniger Tage ein interaktiver Demonstrator: eine Wettkampfszene Mensch gegen Agent mit Agenten-Panels, Startsteuerung und Zwei-Bildschirm-Betrieb. Technisch stützt er sich auf einen Kompatibilitätsmodus für die V24-Inferenz (reduzierter Beobachtungsvektor) und einen Competition-Modus im Agentenskript, der Belohnungs- und Episodenlogik deaktiviert. Der Demonstrator ist ein Nebenprodukt - hinterlässt aber Spuren, die später relevant werden: Der Kompatibilitätsmodus bleibt als Prefab-Voreinstellung

im Projekt.

Juni: Konsolidierungspause

Zwischen dem 27. Mai und dem 8. Juli weist das Repository keine Commits auf. Die Pause trennt die explorative Einzeloptimierung der Architekturen vom methodisch kontrollierten Direktvergleich.

8. Juli: Wiederaufnahme - Standalone-Pipeline und erste Vergleichsläufe (Branch ModelTrainingComparsion)

Der Direktvergleich beginnt mit einem Infrastruktur-Commit: Headless-Build, Watchdog-Skripte für automatische Neustarts, parallele Environment-Prozesse und drei Startvarianten (Editor/Visual/Standalone). Alle drei Architekturen trainieren fortan als drei Behaviors gleichzeitig im selben Environment. Die ersten Läufe (model_comparison_v1 bis v4) starten mit weitgehend identischen Trainer-Konfigurationen und werden zum Härtestest der Infrastruktur: Eine regelmäßige Absturzscheife (~alle 22 Minuten) wird auf Speichererschöpfung beim simultanen Checkpoint-Export dreier Agenten zurückgeführt und über die Puffergröße behoben; der bei jedem Neustart verlorene Curriculum-Fortschritt erhält eine dateibasierte Persistenz je Environment-Worker; das Curriculum bekommt Erfolgsraten-Gates gegen das aus V14 bekannte Phasen-Aussitzen; die Sprungkraft des Agenten wird nach der Diagnose ausbleibender Lava-Überquerungen angehoben. Am Abend fällt die methodische Grundsatzentscheidung: Identische Hyperparameter sind Scheinfairness, da erprobte Arbeitspunkte des Transformers (Lernrate $1e-4$, β $1e-3$) von den MLP/LSTM-Werten abweichen - der Vergleich wechselt auf das Prinzip Best vs. Best mit einzeln begründeten Abweichungen. Gegen 23 Uhr startet der erste finale Vergleichslauf (model_comparison_final).

9. Juli, Nacht und Vormittag: erster finaler Lauf - stabil, aber mit klarem Befund

Der Lauf absolviert die Nacht erstmals über sieben Stunden crash-frei, durchläuft alle Curriculum-Phasen bis Hard und bestätigt die Wirksamkeit der Gates (Lava-Phasen mit 30-38 % Erfolg regulär bestanden - in v4 zuvor: null Überquerungen). Eine Beobachtungssession im Unity-Editor am Vormittag deckt drei weitere Defekte auf, die umgehend behoben werden: eine MissingReferenceException durch Asset-Reimport im laufenden Play-Modus (Null-Guard im CurriculumTracker), 19 verwaiste Layout-Referenzen in der Curriculum-Konfiguration und ein Off-by-one im phasenspezifischen Episoden-Timeout, durch das Environments nach einem Direkteinstieg in die letzte Phase ohne Zeitlimit liefen. Inhaltlich zeichnet sich derweil der zentrale Befund ab: MLP und LSTM lernen die Aufgabe (Hard-Erfolgsraten um 8-12 %, steigend), der Transformer bleibt trotz seiner V14-erprobten Konfiguration nahezu erfolglos (~1 %) - sein moderater Reward stammt aus Shaping-Boni, nicht aus Zielerreichung.

9. Juli, Mittag: Abschluss des ersten Laufs und die entscheidende Diagnose

Bei 3,99 Millionen Steps (rund 13 % des Budgets) wird der Lauf bewusst beendet, vollständig resumierbar archiviert und mit Abschlussbericht ausgewertet. Der Vergleich mit Milestone 7 liefert die Erklärung des Transformer-Scheiterns: Seine Konfiguration war für eine Umgebung mit Zielrichtungs-Observation entstanden - im Vergleichsaufbau fehlte diese Information, der Agent musste das Ziel per Sensor-Kegel suchen statt geführt zu navigieren. Zusätzlich wird ein seit jeher wirkungsloser Belohnungsterm identifiziert: Die Erkennung erfolgreicher Lava-Überquerungen feuerte konstruktionsbedingt nie, der zugehörige Bonus (+8) wurde in keinem Lauf ausgezahlt - für den Vergleich unschädlich (alle Architekturen identisch betroffen), aber als Abweichung zwischen

dokumentierter und effektiver Belohnungsfunktion festzuhalten.

9. Juli, Nachmittag: zweiter finaler Lauf (model_comparison_final_v2)

Die Konsequenzen werden in einem Paket umgesetzt: Der Zielrichtungsvektor kehrt - für alle drei Architekturen identisch - in den Beobachtungsraum zurück (31 Vektor-Observations), ein Loch-Vermeidungs-Penalty ergänzt spiegelbildlich zum Lava-Sprung-Bonus die Belohnung, und das Curriculum wächst auf acht Phasen mit isolierten Gefahren-Lernstufen (TrivialHole, TrivialLava, TrivialHazard - die Rückkehr der M7-Struktur, ergänzt um die bewährten Gates), Gates bis Medium und einer Wiederholungsschleife der oberen Phasen. Durchsatzseitig wird auf drei parallele Environments, time-scale 40 und threaded Training umgestellt (~350-450k Steps/h). Um 14:41 Uhr startet der Lauf; parallel entsteht ein autarkes Training-Kit (Offline-Python-Paket, Build, Monitoring-Skripte) für die Reproduktion auf Fremdhardware.

9.-10. Juli: der zweite Lauf bestätigt die Diagnose

Die Wirkung der Zielrichtungs-Observation zeigt sich unmittelbar: Die ersten Gates fallen mit 40 %, 80 % und 78 % (Loch-Phase) statt in Stunden in Minuten bis wenigen Stunden; die isolierte Lava-Phase wird mit 34 %, die kombinierte Gefahrenstufe - der historische V14-Stolperstein - mit 51 % bestanden. Über Nacht durchläuft der Lauf crash-frei mehrere Curriculum-Schleifen; die Wiederholungsblöcke belegen block-über-block steigende Leistung auf identischen Kartenklassen (Hard-Erfolg LSTM: 33,8 % im ersten, 50,2 % im zweiten Block; Easy-Gates: 44 %, 66 %, 70 %). Der zuvor gescheiterte Transformer löst nun 16-22 % der Hard-Karten mit positivem Reward - das Scheitern des ersten Laufs war ein Informations-, kein Architekturproblem. Die Rangfolge über alle Schwierigkeitsgrade lautet stabil LSTM vor MLP vor Transformer, bei schrumpfenden Abständen. Stand heute Mittag (10. Juli) hat der Lauf rund sieben Millionen von 30 Millionen Steps absolviert und befindet sich in der dritten Curriculum-Schleife; der Abschluss ist für das Wochenende projiziert. Die Generalisierungsmessung auf ungesesehenen Karten (Held-out-Seeds) ist als Abschluss der Evaluation vorbereitet.